

2020학년도 학부생 연구프로그램(UGRP)

최종보고서

과제명	[UGRP] AI를 이용한 인상(人相)의 분석과 앱 개발
-----	---------------------------------

[목차]

1. 연구 목적
2. 연구내용 및 진행
 - (1) 연구 경과
 - (2) 연구 내용
 - a. 연구 개요
 - b. 전처리 과정
 - i. 데이터 수집
 - ii. 데이터 augmentation
 - c. 데이터 Visualization
 - d. 모델 훈련 – Model 1 / Model 2 / Model 3
3. 연구결과 및 활용방안
 - (1) 결과 분석
 - a. 모델 채택 과정
 - b. Model 3의 test set 결과 분석
 - c. Model 3 시연 정확도 및 최종 채택 기법
 - (2) 활용방안
 - (3) 의의
 - (4) 한계 및 고찰
4. 참고문헌

1. 연구 목적

과거의 선인(先人)들이 연구한 '인상학'은 현재 '인상경영학' 등 전문화된 학문의 갈래로 나뉘어 발전해왔다. 인상, 특히 첫인상은 '사람에 대한 호감도'를 결정하고, 나아가 인물을 적재적소에 뽑을 때 고려하는 주된 요인으로 작용하기도 한다. 일례로 미국 다트머스 대학교의 심리, 뇌 과학자 폴 왈렌 교수의 연구에 따르면 인간의 뇌는 0.017초에 상대방에 대한 호감이나 신뢰 여부를 판단할 수 있는데, 이는 첫인상 효과로 불리는 '초두효과' 때문이다. 한편, 근래 각광 받는 AI, 그 중에서도 주로 이미지 데이터를 처리하는 CNN(Convolutional Neural Network)은 단순히 개와 고양이를 분류하는 데 그치지 않고, 다양한 사람의 얼굴을 인식하고 분류하여 여러 작업을 하는 데까지 이르렀다. 위의 대표적인 예시가 사람의 성격(Big5 검사 결과)과 얼굴 이미지의 상관성에 대해서 CNN ResNet 모델을 사용하여 분석한 최신 연구이다([2], 2020년). 아쉽게도 이 외에 성격 유형과 얼굴

이미지 간의 상관관계에 대한 연구가 희박한데, 실제 '유의미한 결과가 나올 수 있을지'에 대한 회의적인 시각, 데이터 수집과 학습 과정에서의 어려움 등이 그 이유일 것이다. 그러나 흔히들 '관상은 과학이다'고 말하는 것처럼, 특히 한 사람의 평소 행동과 표정이 그의 인상을 그와 비슷하게 바꾸는 것처럼, 인상과 성격의 연관성을 아예 부정하기는 쉽지 않다. 따라서 본 연구는 위 두 개가 유의미한 상관관계가 있다고 가정하고, 실제 각 성격이 어떠한 인상학적 특징을 지니며 훈련시킨 모델로 새로운 인상 데이터를 정확히 분류할 수 있는지 알아보기 위해 위 연구를 진행하게 되었다.

2. 연구내용 및 진행

(1) 연구 경과

	활동 내역	장소
6월-8월	1. 연세대 서은국 교수님 e-mail 자문 / 인상경영학 황규봉 박사님과 전화 면담 / 홍성민 소장님과 면담 2. 데이터 크롤링 3. 관련 서적[1] 및 논문[2] 공부(이론 공부)	서울
8월-11월	1. 전처리 작업(augmentation) 2. 박재식 교수님과 Zoom 미팅 3. PCA, T-SNE, LDA 등으로 데이터 클러스터링 및 시각화 4. Xception + 2 layers 모델로 전이학습 진행	포항/ 광주
12월-1월	1. ResNet + MLP 모델로 학습 진행 2. Classification(ML) 진행 3. 웹 시안 제작	포항/ 광주
1월-	1. 모델 및 데이터를 조금씩 변형하여 훈련 진행 2. 데이터 시각화 및 영상 제작 3. 'MBTI 테스트' 웹 제작	포항/ 광주

(2) 연구 내용

a. 연구 개요

초기 연구 방향을 설정할 때 [2]를 참고했다. 다른 점은 Big 5 대신 대중성과 접근성이 높은 MBTI를 성격 진단의 척도로 사용하였다. 최소 몇천 장 이상의 데이터를 확보하기 위해 연예인을 공략했으며, 전처리 과정을 통해 훈련에 적합한 이미지만을 추출했다. 실제 성격과 인상이 관계가 있는지 시각적으로 판단하기 위해 차원 축소 및 시각화 기법을 이용하여 인풋 이미지를 시각화하였다. 논문 [2]에 서술된 ResNet 모델과 이외 다양한 모델들을 여러 방법으로 훈련시킴으로써 인상과 성격의 상관관계를 파악하였고, 최종적으로 학습된 모델을 동결시켜 새로운 input(얼굴 데이터)을 넣었을 때 모델이 판단한 output(MBTI)을 내놓는 웹을 만들었다.

b. 전처리 과정

i. 데이터 수집

Selenium이라는 파이썬 프레임워크를 사용해 각종 SNS에서 2,000여 명의 연예인의 얼굴 이미지와

공개된 MBTI 정보를 크롤링했다. 케이스케이드 기반 분류기와 caffe 모델을 활용하여 정면 얼굴 사진을 검출하기 위한 적절한 코드를 작성하고 자동화하였다. 처음에 수집한 얼굴 이미지는 약 8,000천 장이나, 제대로 된 학습을 위해 얼굴을 가리는 사진, 정면이 아닌 사진, 양쪽 귀가 다 보이지 않는 사진, 큰 마이크를 찬 사진, 감정 표현이 과한 사진 등을 제외시켰다. 최종 확보한 2,000장의 사진을 눈 기준으로 정렬하였다.

ii. 데이터 augmentation

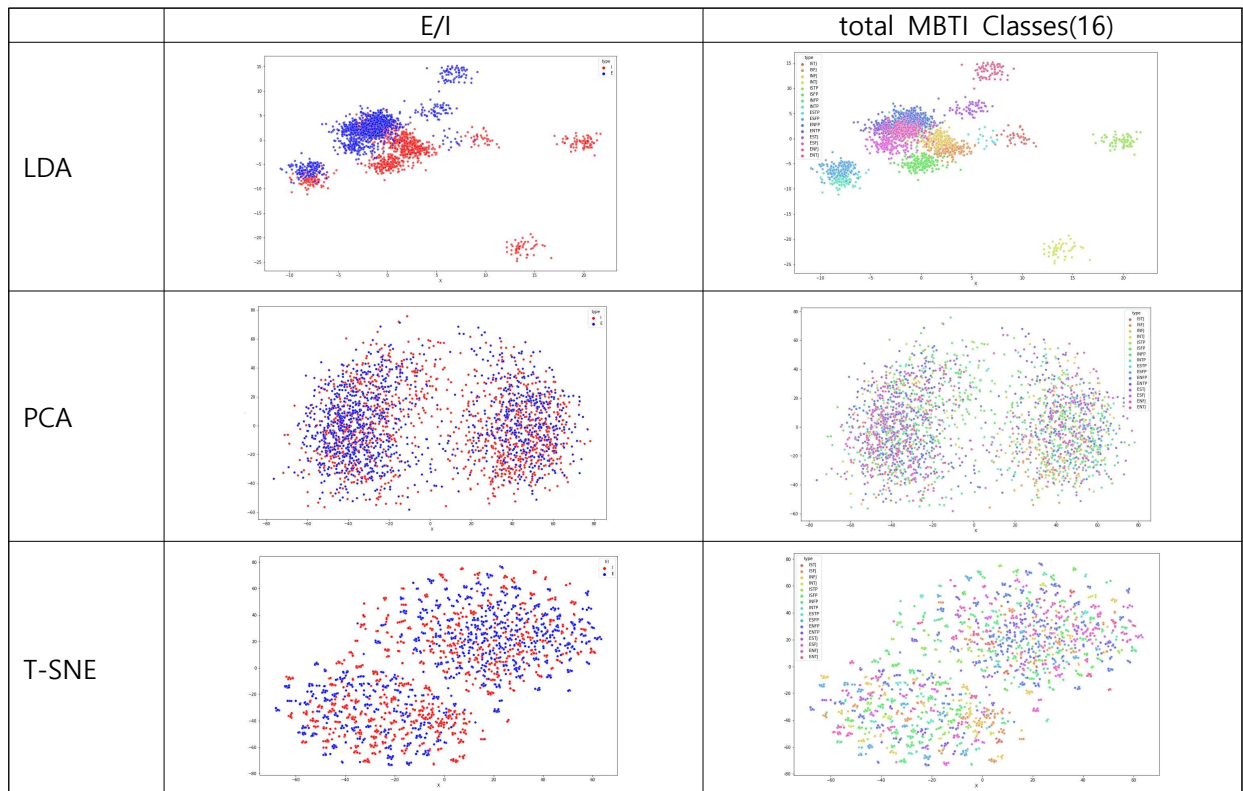
실제 쓰이는 좌우 반전(flip), 그레이 스케일(Grayscale, 회색화)와 같은 augmentation 기법을 이용해서 기존 2,000개의 데이터를 늘리고, edge detecting(sobel filtering)을 활용해서 얼굴의 feature를 직접 뽑기도 하여 이미지 개수를 최종 12,000개로 늘렸다.

c. 데이터 Visualization

[차원 축소 및 시각화 기법]

- * LDA(선형 판별 분석): 데이터를 사영시킨 후 적합한 (선형) 결정경계(Decision boundary)를 찾아 분류하는 기법
- * PCA(주성분 분석): 데이터의 분산을 최대한 보존하면서 서로 직교하는 새 기저를 찾아, 선형 연관성이 적은 저차원 공간으로 차원을 축소하는 기법
- * T-SNE(T-분포 확률적 임베딩): 비선형 차원 축소 기법

이미지 데이터에서 수치형 feature을 추출하기 위해 SENet 기반의 VGG-Face를 사용하였다. 이를 input으로 하여 LDA, PCA, T-SNE로 feature 공간의 차원을 축소시키고 시각화하였다[그림 1]. 한편으로는, 각 Label 별 이미지들의 픽셀 평균값을 계산하고[그림 2] 같은 척도 내의 특성과(예: E와 I, N과 S, F와 T, P와 J), 다른 척도 내의 특성들(예: E와 N 등)의 퍼센티지 차이를 비교해보았다[표 1]. 결과는 다음과 같다.




[그림 1] 차원 축소 기법에 따른 데이터 시각화

특히 LDA의 경우 16개의 label들이 확연하게 cluster 되어 있는 것을 확인할 수 있다.

대비되는 성질	E/I	S/N	T/F	J/P
차이값(%)	1.2%	1.0%	1.68%	1.2%

[표 1] 같은 척도 내 특성들의 차이값(%)



[그림 2] 각 MBTI Average

같은 척도 내 차이값(%) 1.0~1.7%로 1.0%대인 반면, 다른 척도 내의 차이값(%)의 평균은 0.705%으로, 1% 미만이다. 독립적인 특성으로 판단되는 다른 척도끼리의 차이값보다 크다는 것을 확인할 수 있다. 같은 척도 내 대조적인 특성이 인상에 따라 유의미한 차이를 보이므로 인상과 성격간 상관관계가 있다고 결론 지었고, 이에 아래의 연구를 실시했다.

d. 모델 훈련


[Model 1] Xception + 2 layers

ImageNet 데이터셋으로 pre-trained된 Xception 모델에 fully-connected-layer 두 층과 20%의 dropout 을 추가하여 전이학습을 실시하였다. '전이학습'이란 상대적으로 데이터의 양이 적을 때, 기존에 만들어진 모델의 가중치 값을 빌려와 적은 데이터로 모델을 훈련시키는 방법이다. 따라서 이미 잘 훈련된 모델이 있고, 만드려는 모델과 유사한 문제를 해결하는 경우에 전이학습을 사용한다. 전이학습에는 크게 세 가지 유형이 존재하는데, 기존 모델 뒤에


- (i) fully connected layer를 연결
- (ii) global average pooling와 그 뒤에 logistic classifier 연결
- (iii) SVM등의 머신러닝 기법을 사용

하는 방법이 그것이다. 여기서는 (ii)를 채택하였다. Xception은 Inception(CNN 기법 중 하나)의 확장된 버전, 즉 Extreme Inception의 줄임말로, 채널간 연관성과 공간적 연관성을 함께 mapping 하지 않도록 분리한다는 Inception 가설의 극단적인 버전이다. 이 모델은 1x1 convolution으로 채널간 연관성(cross-channel correlation)을 mapping하고, 각 채널의 공간적 연관성(spatial correlation)을 따로 mapping한다.

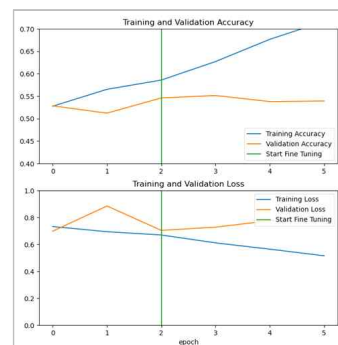
본 실험은 데이터가 상대적으로 적었다. 따라서, 기존 Xception 모델을 완전히 다시 학습시키는 대신, 기존 모델의 잘 학습되어 있는 특징점 추출을 이용하였다. 먼저, 빌려온 모델의 학습을 막은 상태에서, 뒤에 연결된 분류기 (fully connected layer)만 1차적으로 학습 시켰다. 그 후, pre-trained model 의 총 126개의 층 중 하위 20개의 층을 풀어서 뒤에 추가한 분류기와 함께 fine tuning 하는 방식으로 훈련을 진행했다. 홍성민 소장의 자문으로 외양적으로는 E와 I의 특성이 가장 잘 드러난다고 판단하였고, 실제 데이터도 반반으로 균일하게 분포되어 있었기 때문에, input(얼굴 데이터)을 넣었을 때 output으로 E 또는 I의 값을 내놓도록 구현하였다. training set : validation set : test set = 80 : 16 : 4이며 데이터 셋(2,000장)으로 기본적인 Data augmentation 등을 진행한 후, 훈련을 진행하였다.



[그림 3] Model 1
Flow Chart



[그림 4] 예측값 (실제값)
0~0.5: E / 0.5~1: I로 예측



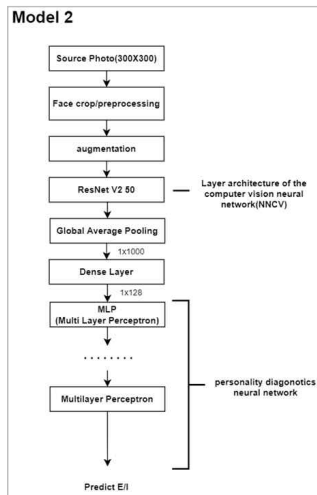
[그림 5] Epoch에 따른 loss

```
Epoch 3/5
119/119 [=====] - 263s 2s/step - loss: 0.6359 - accuracy: 0.6107 - val_loss: 0.7278 - val_accuracy: 0.5515
Epoch 4/5
119/119 [=====] - 259s 2s/step - loss: 0.5803 - accuracy: 0.6648 - val_loss: 0.7751 - val_accuracy: 0.5379
Epoch 5/5
119/119 [=====] - 259s 2s/step - loss: 0.5310 - accuracy: 0.7083 - val_loss: 0.7701 - val_accuracy: 0.5393
6/6 [=====] - 7s 1s/step - loss: 0.7294 - accuracy: 0.5990
Test accuracy : 0.5989583134651184
```

[그림 6] Epoch에 따른 정확도와 Test accuracy

[Model 2] ResNet-50 + MLP

위 시도에서는 논문 [2]에서 사용된 모델을 차용하였다. 기존 CNN은 convolution layer 다음에 FC(fully connected) 레이어를 가지고 있으며, 그 예시인 AlexNet, ZFNet, VGGNet 등은 skip이 없는 plain networks이다. 여기서 network의 깊이가 증가하면 gradient vanishing 문제가 간혹 발생하는데, 이를 해결하기 위해 등장한 모델이 ResNet이다. 이 중 ResNet-50 모델에 MLP를 추가하여 학습을 진행시켰고, [시도 1]에서와 마찬가지로 output으로 E와 I 중 하나를 내놓도록 구현하였다. training set : validation set : test set = 70 : 15 : 15이며, data augmentation 이전의 데이터 셋 (2,000장)으로 훈련을 진행하였다.



[그림 7] Model 2 Flow Chart

```
Epoch 96/100
363/363 [=====] - 376s 1s/step - loss: 0.5899 - accuracy: 0.6497 - val_loss: 0.7146 - val_accuracy: 0.5621
Epoch 97/100
363/363 [=====] - 377s 1s/step - loss: 0.5864 - accuracy: 0.6518 - val_loss: 0.7214 - val_accuracy: 0.6065
Epoch 98/100
363/363 [=====] - 377s 1s/step - loss: 0.5864 - accuracy: 0.6588 - val_loss: 0.7374 - val_accuracy: 0.5923
Epoch 99/100
363/363 [=====] - 376s 1s/step - loss: 0.5915 - accuracy: 0.6468 - val_loss: 0.7141 - val_accuracy: 0.5669
Epoch 100/100
363/363 [=====] - 377s 1s/step - loss: 0.5819 - accuracy: 0.6686 - val_loss: 0.7825 - val_accuracy: 0.5882
```

[그림 8] Epoch에 따른 train accuracy & validation accuracy

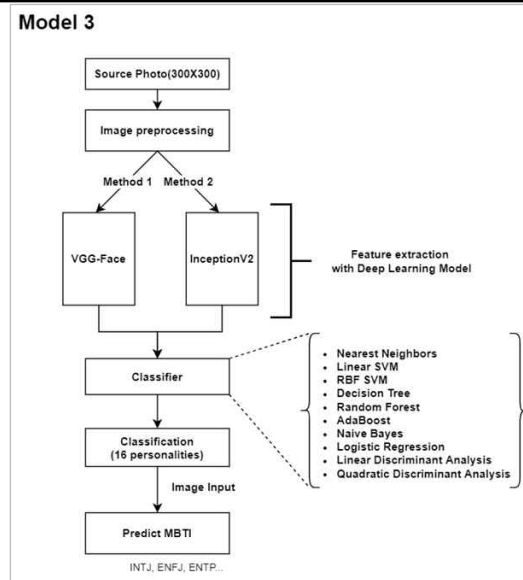
[Model 3] Various ML(Machine Learning) Classifications

(Step 1) Deep Learning으로 feature 추출

VGG-Face(Method 1)와 InceptionResNetV2(Method 2)를 사용하여 feature를 추출하였다.

(Step 2) Machine Learning으로 classification 진행

a에서 얻은 feature들로 classification을 진행하였다. 여기서의 classifier들은 전통 Machine Learning의 지도학습 모델들로 input은 feature, output은 16개의 label 중 하나이다. training : test = 8 : 2 비율로 각각 2,000장과 12,000장을 가지고 훈련을 시켰다. 사용된 Classifier는 Nearest Neighbors(NN), Linear SVM, RBF SVM, Decision Tree, Random Forest, AdaBoost, Naive Bayes, Logistic Regression, Linear Discriminant Analysis, Quadratic Discriminant Analysis 총 10개이다. 위 10개의 ML Classifier들을 각각 VGG with no augmentation(2,000장) / VGG with augmentation(12,000장) / InceptionResNetV2 with no augmentation 세 경우로 나누어 훈련시켰다 (총 30가지).



[그림 9] Model 3 Flow Chart

기법	설명
NN	가장 가까이 있는 centroid를 중심으로 데이터의 class를 update하는 기법
Linear SVM	학습 데이터와 가장 먼 거리를 가지는 초평면을 찾아 데이터를 분류하는 기법
RBF SVM	선형으로 분류될 수 없는 데이터들을 분류하기 위해 만들어진 Kernel SVM의 가장 대표적인 예시.
Decision Tree	특정 기준에 따라 데이터를 구분하는 모델
Random Forest	여러 개의 Decision Tree를 형성하고 각 Tree가 분류한 결과에 투표를 실시하여 가장 많이 득표한 결과를 최종 분류 결과로 선택하는 기법
AdaBoost	weak classifier들이 상호보완 하도록 단계적으로 학습하고 이들을 조합한 strong classifier의 성능을 증폭시키는 기법
Naive Bayes	베이즈 정리를 이용한 확률 분류기의 일종
Logist Regression	로지스틱 함수를 사용하여 얻은 종속 변수의 값으로 분류를 실시할 수 있는 모델
Linear Discriminant Analysis(LDA)	데이터를 사영시킨 후 적합한 (선형) 결정경계(Decision boundary)를 찾아 분류하는 기법
Quadratic Discriminant Analysis(QDA)	LDA의 결정경계를 2차식으로 대체한 기법

[표 2] ML Classifier 설명

3. 연구결과 및 활용방안


(1) 결과 분석

a. 모델 채택 과정

본 연구에서는 크게 세 개의 model을 훈련시켰다. Model 1의 accuracy는(E와 I를 정확히 예측할 확률)은 59.9%이며, Model 2의 train/validation accuracy가 epoch에 따라 증가하는 것에서 model 올바르게 train 된 것을 확인할 수 있었다. 생각보다 E/I 예측 정확도가 높지 않았고, 이미지 데이터를 통째로 넣어 Deep learning 기법(Model 1, Model 2)으로 학습시키는 것보다, 이미지의 feature를 추출한 후, 이 유사성을 바탕으로 분류하는 방법(Model 3)이 실제 정확도가 높다고 판단해 Model 3을 채택하였다.


b. Model 3의 test set 결과 분석

Model 3의 결과(알파벳 네 개를 다 맞출 확률)는 [그림 10]에서 확인할 수 있다.



[그림 10] MBTI Accuracy

위 차트를 보면 augmentation 데이터를 사용한 경우와 사용하지 않은 경우 중 일반적으로 어떤 것이 우위라는 결론을 얻을 수 없다(파란색, 주황색 비교). 이미 한 사람당 평균적으로 5장의 사진을 사용했으며, augmentation이 모델들의 정확도를 일관적으로 높이지 못했기 때문에, 실제 시연할 때(c)는 no augmentation 데이터 셋을 이용했다. 다음은 no augmentation 데이터를 사용한 모델들의 정확도를 수치로 나타낸 것이다. 위 표에서, 꽤 높은 정확도(0.12 이상)를 가지는 classifier들이 존재함을 확인할 수 있다. 랜덤하게 알파벳을 골랐을 때 MBTI를 맞출 확률이 $1/(2*2*2*2)=1/16=0.067$ 인데 반해, 특정 classifier들은(예: RBF SVM) 랜덤한 경우보다 정확도가 2배 이상 높다. 한 가지 고려해야 할 점은 INFP와 INFJ처럼 알파벳이 하나만 다를 경우에도 모두 '틀린 경우'로 처리했기 때문에, 각 알파벳 기준으로 봤을 때의 정확도(예: INFP를 INFJ로 판단했을 때의 정확도는 0.75)[그림 11]는 0.5~0.6까지 올라가게 된다.



[그림 11] 알파벳별 MBTI accuracy

c. Model 3 시연 정확도 및 최종 채택 기법

다음은 본 연구에 참여한 연구원들의 얼굴을 최종 열린 모델에 넣은 결과이다. 실제 MBTI와 20개의 Classifier들(VGG-Face 기반/InceptionResnetV2 기반 * Classifier 10개)이 도출한 MBTI output을 비교한 결과가 아래 표에 정리되어 있다. [표 3]에서 정확도가 75%에 육박하는 classifier들이 존재하며(NN based InceptionResnetV2, Naive Bayes), [표 4]에서 우수한 classifier들이 일반적으로 실제 MBTI의 알파벳 중 적어도 3개는 맞춘다는 것을 확인할 수 있다. 본 연구에서는 가장 우수하다고 판단된 Random Forest on VGG-Face model을 실제 웹을 제작할 때 채택하였다.

	Classifier	Accuracy	Model
0	Nearest Neighbors	0.500000	VGG
1	Nearest Neighbors	0.750000	InceptionResNetV2
2	Linear SVM	0.650000	VGG
3	Linear SVM	0.650000	InceptionResNetV2
4	RBF SVM	0.700000	VGG
5	RBF SVM	0.700000	InceptionResNetV2
6	Decision Tree	0.650000	VGG
7	Decision Tree	0.550000	InceptionResNetV2
8	Random Forest	0.650000	VGG
9	Random Forest	0.700000	InceptionResNetV2
10	AdaBoost	0.600000	VGG
11	AdaBoost	0.350000	InceptionResNetV2
12	Naive Bayes	0.750000	VGG
13	Naive Bayes	0.750000	InceptionResNetV2
14	Logistic Regression	0.650000	VGG
15	Logistic Regression	0.700000	InceptionResNetV2
16	Linear Discriminant Analysis	0.300000	VGG
17	Linear Discriminant Analysis	0.550000	InceptionResNetV2
18	Quadratic Discriminant Analysis	0.500000	VGG
19	Quadratic Discriminant Analysis	0.500000	InceptionResNetV2

[표 3] 시연 시 각 Classifier 정확도

	Classifier	Model	Haeun	Jong Yeop	Jun Hyeong	Hyunju	Byungjun
0	Answer	None	INTP	ENFJ	ENFJ	ENTP	ENTP
1	Nearest Neighbors	VGG	ENFP	ENFP	INTP	ISTP	ENFJ
2	Nearest Neighbors	InceptionResNetV2	INTP	INFP	INFP	ENFP	ENTP
3	Linear SVM	VGG	INTP	ENFP	INTP	INFP	INTP
4	Linear SVM	InceptionResNetV2	ISTP	INFP	ENFJ	ENFJ	ENFJ
5	RBF SVM	VGG	ENFP	ENFP	ENFP	ENFP	ENFP
6	RBF SVM	InceptionResNetV2	ENFP	ENFP	ENFP	ENFP	ENFP
7	Decision Tree	VGG	ENFP	ENFP	ENFP	ENFP	ENFJ
8	Decision Tree	InceptionResNetV2	INFP	INFP	INFP	INFP	ENFJ
9	Random Forest	VGG	ENFP	ENFP	INFP	ENFP	ENFP
10	Random Forest	InceptionResNetV2	INFP	ENFP	ENFP	ENFJ	ENFP
11	AdaBoost	VGG	INFP	INFP	ENFP	INFP	INFP
12	AdaBoost	InceptionResNetV2	ESFP	ENFP	ISFP	ISFP	ESFJ
13	Naive Bayes	VGG	INFP	ENFP	ENFP	ENFP	ENFP
14	Naive Bayes	InceptionResNetV2	ENTP	ENTJ	ENTP	ENTP	ENTJ
15	Logistic Regression	VGG	INTP	ENFP	INTP	ISTP	INTP
16	Logistic Regression	InceptionResNetV2	ISTP	INFP	ENFJ	ENTJ	ENFJ
17	Linear Discriminant Analysis	VGG	ENTP	ISTP	ISFJ	ESFJ	ISFJ
18	Linear Discriminant Analysis	InceptionResNetV2	INFJ	ESTP	ENFP	ENTP	ISFP
19	Quadratic Discriminant Analysis	VGG	ISFP	ENFP	INTJ	ISFP	ESFP
20	Quadratic Discriminant Analysis	InceptionResNetV2	ENTP	ENTP	ISFJ	ESFP	ISFP

[표 4] 시연 시 각 Classifier Output

(2) 활용방안

여러 플랫폼들이 빅데이터를 다루게 되면서 AI나 간단한 알고리즘을 통한 재미있는 테스트들이 인터넷에서 유행이다. 일례로 본인의 얼굴을 넣으면 무슨 상(이성운이 좋은 관상, 평생 재물운은 타고난 관상 등)인지를 알려주는 “관상 테스트”(Youtube 채널 '조코딩(JCoding)' 제작), 마찬가지로 얼굴을 넣으면 무슨 동물과 비슷한지(토끼상, 곰상 등) 알려주는 “동물상 테스트” 등이 있는데, 특히 ‘관상 테스트’는 네이버 실검 1위까지 오르며 네티즌들의 큰 호응을 얻었다. 이와 비슷하게 ‘인상 MBTI 테스트’를 앱이나 웹 서비스로 출시한다면, 네티즌들의 흥미를 유발할 뿐만 아니라 이용 시 모인 새로운 데이터들로 계속해서 모델을 훈련시킬 수 있다. 이렇게 얻은 모델이 실제 인상과 성격 간 강한 상관관계를 보여준다면 인상을 과학적으로 접근할 수 있는 발판을 마련함과 동시에, 향후 인상학이나 뇌과학, 심리학 연구에 긍정적인 영향을 미칠 수 있을 것이다.



[그림 12]
출시될 웹 서비스

(3) 의의

본 연구는 다음의 의의를 갖는다.

첫째, 본 연구는 인상과 성격(MBTI) 간의 유의미한 상관관계가 있음을 보였다. 이는 선행 연구[2]와의 비교를 통해서도 확인할 수 있다. [2]의 연구는 5개의 label을 가지는 Big 5 검사 결과를 활용하여 인상과 성격의 상관관계를 분석하였다. 11202명의 사람, 28230개의 이미지, 애초에 우수한 이미지(정면 사진)를 사용하여 ‘58%의 성격 정확도’를 얻은 [2]와 대조했을 때, 비교적 적은 데이터와 덜 정갈한 얼굴 데이터(증명사진이 아닌 활동사진이 많음)를 사용해 ‘50~60%의 성격 정확도’를 얻은 본 연구의 모델도 유의미한 결론을 도출했다고 해석할 수 있다. 실제 5명의 연구원을 대상으로 모델들을 시연했을 때 80%의 높은 확률을 보인 경우도 있었다. 본 연구는 특히, 지금까지 MBTI와 한국인 인상의 상관관계를 분석한 연구가 없었다는 점에서 희소성을 갖는다.

둘째, 데이터 전처리, 시각화, 훈련 시 사용한 여러 code들을 github으로 공유해서, 본 주제와 관련된 연구들의 진입 장벽을 낮췄다.

셋째, '얼굴로 유추한 MBTI 테스트' 웹 서비스의 출시는 사람들의 "인상-성격 상관관계"에 대한 관심을 높이고 인상학, 심리학의 과학적 접근을 가능케 할 것이다.

(4) 한계 및 고찰

두 가지 한계점이 존재했다. 첫째, 사용된 데이터의 수가 부족했다. 훈련 시 사용된 데이터는 총 12,000장이지만 이는 기존 2,000장의 연예인 얼굴 데이터를 각종 augmentation을 통해 증가시킨 것이기 때문에 실제 몇만 장의 단위로 학습을 진행하는 CNN보다 사용된 인풋 데이터 수가 적었다고 볼 수 있다. MBTI와 얼굴 데이터가 공개되어있는 인물로 데이터가 제한되다 보니 생긴 한계였다. 물론 아래 (3) 활용방안에 나와 있는 것처럼, 웹 서비스 출시를 통해 보다 많은 사람들의 얼굴과 그에 상응하는 MBTI를 얻는다면 데이터 부족 문제를 해결할 수 있을 것이다. 제작된 앱은 법률 자문을 받은 후 출시할 계획이다.

두 번째 한계점은, 결과에 대한 깊은 해석이 부족했다는 점이다. 당초 계획에는 얼굴의 어떤 부분, 어떤 특징이 어떤 성격에 기여하는지 그 가중치를 계산하는 것도 포함되어 '인상'에 좀 더 과학적으로 접근하고 싶었으나, 본 연구는 전반적인 평균치와 정확도를 계산하고 눈으로 그(각 성격 유형별 평균적인 얼굴상)를 확인하는데 그쳤다. 이에 (i)PCA나 등의 기법으로 주요 성분을 뽑아 이미지를 변화시킨 후 각 부위별 가중치를 계산하거나, (ii)explainable feature space를 가지는 GAN을 통해, 각 feature들을 t-SNE로 클러스터링 한 후, 실제 인상학에서 말하는 feature 결과값과 비교해보는 활동을 후속 연구로 제안한다.

4. 참고문헌

- [1] Aurelien Geron. (2018). 핸드즈온 머신러닝 (박해선 역). 한빛미디어. (2017).
- [2] Alexander Kachur et al. (2020). Assessing the Big five personality traits using real-life static facial images. Scientific Reports. Vol 10. P 8487.

본 연구에서 사용한 코드를 저장한 github 주소

- >> <https://github.com/unajun/2020-ugrp-Face-analysis-MBTI>
- >> <https://github.com/haeunlee22/2020-ugrp-MBTI>

학부생 연구프로그램(UGRP) 개인정보 및 성과물 활용 동의서

개인정보 수집 및 활용 동의서

본인은 교육혁신센터의 '학부생 연구프로그램(UGRP)'의 교육적 운영을 위해 팀의 결과물로 제출한 내용에 포함된 개인정보 및 관련한 행사에서의 초상권을 이용하는데 동의합니다.

1. 개인정보 수집·활용 목적: 프로그램 운영, 관련 보고문서 작성, 비영리 교육홍보자료 이용, 교내 공유 등
2. 개인정보 수집 항목: 성명, 학년, 학과, 학번, 초상권
3. 개인정보 보유 및 이용기간 : 개인정보 수집 및 이용 목적의 종료 시까지

☒ 개인정보 수집 및 이용에 동의함

☐ 동의하지 않음

본인은 위의 모든 내용을 충분히 확인하였으며, 이에 서명합니다.

2020 년 1 월 13 일

대표자
(팀장)

학번/성명: 20190472 / 선종엽 (서명)

포항공과대학교 귀하